GLM-4.7-Flash · Minerva Math

Figure 3

Original · Expert · FFN · Layer · 10% pruning · 30% pruning · 50% pruning

A Output length

All responses · Untruncated

Total parameters | Active parameters | Estimated FLOPs | Decode time

Mean output tokens: 8,192 · 4,096 · 0

B Accuracy and coverage

pass@1 · pass@512

Pass@k (%): 100 · 50 · 0

C Truncation rate

Truncated responses (%): 100 · 50 · 0

15 · 20 · 25 · 30 — Billion parameters

2.0 · 2.5 · 3.0 · 3.5 — Billion parameters/token

2.4 · 3.2 · 4.0 — TFLOPs/request

3.0 · 4.5 · 6.0 — ms/output token